

HSEA-2026


Assignment 4

2026/05/22




自然科学四大
基础科学问题
之一：
生命起源与演化

地层剖面中海量化石记录数据



生物多样性变化曲线



利用化石记录重现生命演化历史


序列优化问题：为不同物种的“首现”和“末现”事件排序，使其与地层剖面中观测到的化石数据尽可能一致

研究问题 – 生物多样性曲线优化


地层剖面中海量化石记录数据



物种首末现事件排序



生物多样性曲线



利用化石记录重现生命演化历史

问题建模：将生物多样性曲线优化问题建模为物种首末现事件的**序列优化问题**

解：所有物种首末现事件的**排序**


优化目标：使所有物种首末现事件的排序与地层剖面中的化石数据**一致**

研究问题 – 生物多样性曲线优化

简单例子

两条剖面：
Seymour Is. Section A (西摩岛上采集的剖面 A)
Seymour Is. Section F (西摩岛上采集的剖面 F)


两个物种：

四个事件：




首现、末现




首现、末现

问题：为这四个事件排序，
使其与右图中观测到的数据尽可能一致



研究问题 – 生物多样性曲线优化

四个事件的所有可能序列（即所有可能的解）



... green+ ... green- ... red+ ... red- ...

... green+ ... red+ ... green- ... red- ...

... green+ ... red+ ... red- ... green- ...

... red+ ... green+ ... green- ... red- ...


... red+ ... green+ ... red- ... green- ...

... red+ ... red- ... green+ ... green- ...

+ 首现
- 末现


研究问题 – 生物多样性曲线优化

四个事件的所有可能序列（即所有可能的解）




目标：延限延展量 越小越好

为使实际观测数据与序列保持一致，
对数据所需做的延展量



共生约束




序列1和6不满足
共生约束


研究问题 – 生物多样性曲线优化

四个事件的所有可能序列

目标：延限延展量 越小越好



序列2的目标值 序列3的目标值 序列4的目标值 序列5的目标值





最小

研究问题 – 重要


1. 生物多样性曲线能够重现生命演化历史，揭示生命起源与演化（自然科学四大基础科学问题之一）

2. 将生物多样性曲线与已有的气候曲线对比分析，可揭示某个历史时期气候剧变对生物多样性变化的影响，从而帮助评估当今的生物多样性问题、预测潜在的生物多样性危机



生物多样性曲线

+



气候变化曲线




评估当前问题
预测未来危机

研究问题 – 难

目标函数黑盒

无法写出解析式


解为序列表示



大规模黑盒序列约束优化问题

十分困难!

搜索空间规模大




搜索空间规模
关于物种数呈指数级增长

问题带约束

例如：共生约束，即两个物种的存在时期必须有交集

以往算法 – 基于模拟退火

以往算法主要流程 基于模拟退火




南大樊隽轩教授、沈树忠院士等人

中国的地层剖面数据
3122个剖面
11268个物种

模拟退火
→
“天河2号”
700万核时

全球第一条高精度 海洋生物多样性曲线



Science Contents News Careers Journals

SHARE RESEARCH ARTICLE
A high-resolution summary of Cambrian to Early Triassic marine invertebrate biodiversity
Jun-xuan Fan^{1,2}, Shu-zhong Shen^{1,2,3,*}, Douglas H. Erwin^{4,5}, Peter M. Sadleir⁶, Norman MacLeod¹, Qiu-min...

Science: “新的数据集和方法，推动整个演化生物学的变革”

Nature: “古生物学家以惊人的细节绘制地球3亿年历史”


2020 年中国十大科技进展

以往算法 – 局限性

优化框架：模拟退火

初始化：随机初始化

新解生成：局部扰动



低效，易于陷入局部最优

例如：地科 Science'20 工作

地层剖面数据	搜索空间规模	“天河2号”
中国：3122个剖面、11268个物种	22536!	700万核时

现有算法不适用于更大规模的数据，无法精准地反应生命演化历史

随着数据收集能力的提升，数据规模越来越大，因此研究高效算法十分重要


三处 定制化设计

合作提出演化算法



② 考虑多样性的交叉算子

从较优解库中选取与当前解差异较大且质量较好的解用于交叉，提高算法的全局搜索能力



- ① 基于领域知识的解初始化：
对数据集中的地层剖面进行统计分析并赋权，优先考虑权重较大的剖面



Evolutionary Algorithm



演化框架



③ 基于学习的自适应变异算子



应用案例4：生命起源与演化

地科团队收集的数据集

数据来源广：分布于全球范围内多个站点

数据规模大：剖面数: 161；物种数: 1291

该数据集是目前全球最大规模的有孔虫数据集



算法	目标值 范围	运行时间
以往算法	39914-41390	~40684s
新算法	39252-39778	~2376s

效率提升17倍，目标值更好
精准重现生命演化

应用案例4：生命起源与演化

高精度的有孔虫多样性变化曲线有助于精确分析其与气候环境变化的关系

	$\delta^{18}\text{O}$		Sea level		Temperature		$\delta^{13}\text{C}$	
	ρ	P	ρ	P	ρ	P	ρ	P
	显著负相关		显著正相关					
F	-0.60	<0.01	0.63	<0.01	0.49	<0.01	0.10	>0.05
PF	-0.85	<0.01	0.74	<0.01	0.70	<0.01	0.02	>0.05
LBF	-0.86	<0.01	0.74	<0.01	0.78	<0.01	-0.07	>0.05
SBF	-0.07	>0.05	0.17	>0.05	0.05	>0.05	0.13	>0.05

浮游有孔虫和大型底栖有孔虫的灭绝与快速降温、海平面下降和正碳同位素偏移有关

揭示E-O过渡期有孔虫生物多样性变化的驱动机制
帮助预测生物多样性危机

作业细节：项目概览

EarthBench 是一个组合优化 benchmark 框架，核心目标是优化生物多样性曲线（CONOP / CONOPLib）——即在地质年代序列上排列生物事件（FAD/LAD），使与观测数据的 mismatch 最小。

项目整体架构：

configs/	→ Hydra 配置 (task + algorithm)
benchmarks/	→ 三类问题的定义与评估
algorithms/	→ EA / BO / RL 等优化器
Environments/	→ RL 训练用的 Gym 环境
main.py	→ Ray 并行评估 + 优化主循环

解的表示：

算法内部表示（一维整数排列）：

```
# 长度 = dims, 元素为 0..dims-1 的不重复排列
x = [0, 2, 1, 3, 5, 4, ...] # 例如 dims=124
```

编码规则 (encode_soln / decode_soln)：

内部编码 soln[i]	解码为 (a_val, b_val)	含义
0	(1, 1)	taxon 1 的 FAD
1	(1, 2)	taxon 1 的 LAD
2	(2, 1)	taxon 2 的 FAD
3	(2, 2)	taxon 2 的 LAD
...	...	...

公式：

- 编码： $\text{soln} = (\text{a_val} - 1) * 2 + (\text{b_val} - 1)$
- 解码： $\text{a_val} = \text{soln} // 2 + 1, \text{b_val} = \text{soln} \% 2 + 1$

作业细节：项目概览

保存格式：

```
[{"x": [0, 2, 1, 3, ...], "y": -1234.5}]
```

`x` 为内部排列编码，`y` 为对应 fitness。

数据集规模：

数据集规模 (dims = 事件数)：

数据集	dims
CONOPLib_124	124
CONOPLib_278	278
CONOPLib_902/904	902/904
CONOPLib_934	934
CONOPLib_2538	2538
CONOPLib_2574	2574
CONOPLib_2582	2582

解的评估：

1. Earth / CONOPLib 评估流程

评估在 `benchmarks/CONOPLib_*/call.py` 的 `EarthBenchmark.__call__` 中完成，分三步：

Step 1: 约束修复 (repair)

任意排列不一定合法，需先修复：

- **FADLAD 约束** (`Fb4L.dat`)：同一 taxon 的 FAD 必须排在 LAD 之前
- **Coexistence 约束** (`coex.dat`)：某些 taxon 对不能交叉出现

`repair()` 通过交换/插入元素使解满足约束。

Step 2: 约束校验

```
assert self.checkFADLAD(x) == True
assert self.checkcoex(x) == True
```

Step 3: 调用 C++ 库计算 penalty

```
pen1 = self.so.getPenalty(carray, len(x)) # CONOPLib.so
if self.maximize:
    pen1 = -pen1 # 取负，使越大越好
```

`CONOPLib.so` 是 CONOP 地学软件的编译产物，根据排列计算与观测剖面数据的 mismatch penalty。penalty 越小（越接近 0）表示解越好；取负后 fitness 越接近 0 越好。

作业细节：任务要求

Task1 (60 pts)

- 实现、应用基本的演化算法，使用课程中所讲的几种交叉变异算子，对比他们的性能进行对比分析 (项目中包含 EA 算法和算子的基本实现)
- 尝试针对特定任务 (CONOPLib_124、CONOPLib_934、CONOPLib_2582) 设计出最优的 EA 算法，并分析算法为什么 work

Task2 (40 pts)

- 对方法进行改进，可从问题降维、可学习算子等角度考虑 (项目中支持基于强化学习的神经重组算子)

作业的评分主要参考演化算法的改进实现、实验效果、实验报告与实验过程中的思考。报告要求与前几次实验一致，提交到

<https://box.nju.edu.cn/u/d/1bc00bf00cb341b7bc70/>

截止日期：2026. 06. 21